Relatório Técnico: Análise Integrada de Educação (Censo Escolar) e Nutrição (SISVAN)

1. INTRODUÇÃO

Este documento detalha os procedimentos de extração, transformação e carga (ETL), bem como os tratamentos e regras de negócio aplicados aos dados do Censo Escolar e do Sistema de Vigilância Alimentar e Nutricional (SISVAN). O objetivo central desta análise é relacionar as condições de infraestrutura das escolas (como acesso à internet e saneamento básico) e os indicadores de saúde e nutrição dos alunos com o seu respectivo rendimento escolar (taxas de aprovação e abandono). A disponibilização destes dados limpos em Dashboards interativos no Power BI permite aos tomadores de decisão visualizarem, de forma clara, o impacto que o ambiente escolar e a segurança alimentar exercem sobre o sucesso acadêmico no Brasil.

2. EXTRAÇÃO DE DADOS

A extração dos dados brutos foi realizada conectando-se ao Google BigQuery (via projeto Base dos Dados). Conforme diretriz do projeto, o código fonte em Python (PySpark/Pandas) utilizado para consumir a API do BigQuery foi separado e será enviado em um arquivo de script (.py) independente. Isso garante que este relatório foque estritamente na modelagem SQL e nas regras de negócio.

3. CONSULTAS SQL E MODELAGEM NO BIGQUERY

Abaixo estão todas as consultas SQL utilizadas para a extração, tratamento e consolidação (JOINs) das informações diretamente no banco de dados. O código foi devidamente identado para garantir total legibilidade.

Consulta 1: Criação da Tabela Master (Consolidação e Tratamento)

Esta consulta utiliza CTEs (Common Table Expressions) para pré-agregar os dados do Censo Escolar e do SISVAN por município e ano, antes de realizar os JOINs. Isso evita a duplicidade de registros (o famoso "produto cartesiano") e melhora a performance da query.

```
-- Criação da tabela analítica final (BigQuery)
CREATE OR REPLACE TABLE `projeto-final-509412.ind_edu.master_saude_educacao_final` AS
WITH censo_agregado AS (
    SELECT
        ano,
        id_municipio,
        SUM(quantidade_escolas) AS total_escolas_publicas,
        AVG(taxa_aprovacao) AS taxa_aprovacao_ef,
        AVG(taxa_abandono) AS taxa_abandono_ef,

        -- Conversão de escala para salvar em formato inteiro (x10000)
        -- Motivo: Evitar problemas de floating point e reduzir custo de
armazenamento.
        CAST(AVG(pct_agua_potavel) * 10000 AS INT64) AS pct_escolas_agua_potavel,
        CAST(AVG(pct_alimentacao) * 10000 AS INT64) AS
pct_escolas_oferecem_alimentacao
    FROM
        `basedosdados.br_inep_censo_escolar.municipio`
    WHERE
        rede = 'Publica'
        AND ano BETWEEN 2017 AND 2023
    GROUP BY
        ano,
        id_municipio
),

sisvan_agregado AS (
    SELECT
        ano,
        id_municipio,
        SUM(total_avaliados) AS total_avaliados_escolares,
        SUM(qtd_vulnerabilidade_nutricional) AS qtd_vulnerabilidade_nutricional
    FROM
        `basedosdados.br_ms_sisvan.municipio`
    GROUP BY
        ano,
        id_municipio
)

-- Tabela Final unindo os dados com os nomes dos municípios
SELECT
    c.ano,
    c.id_municipio,
    d.nome AS id_municipio_nome,
    d.sigla_uf,
```

```
    c.total_escolas_publicas,
    c.taxa_aprovacao_ef,
    c.taxa_abandono_ef,
    c.pct_escolas_agua_potavel,
    c.pct_escolas_oferecem_alimentacao,
    s.total_avaliados_escolares,
    s.qtd_vulnerabilidade_nutricional
FROM
    censo_agregado c
LEFT JOIN
    sisvan_agregado s
    ON c.id_municipio = s.id_municipio
    AND c.ano = s.ano
LEFT JOIN
    `basedosdados.br_bd_diretorios_brasil.municipio` d
    ON c.id_municipio = d.id_municipio;
```

Consulta 2: Verificação Exploratória de Nulos (SISVAN)

Consulta utilizada para auditar a qualidade da base do Ministério da Saúde antes do JOIN, identificando quantos municípios efetivamente enviaram dados em cada ano.

```
-- Consulta exploratória para identificar anos com lacunas de dados
SELECT
    ano,
    COUNT(id_municipio) as qtd_municipios_com_dados
FROM
    `basedosdados.br_ms_sisvan.municipio`
WHERE
    qtd_vulnerabilidade_nutricional IS NOT NULL
GROUP BY
    ano
ORDER BY
    ano;
```

4. TRATAMENTO DE ANOMALIAS E REGRAS DE NEGÓCIO

4.1. A Questão dos Zeros e Escalas (Tratamento no Power BI)

Durante a análise e importação no Power BI, notou-se que alguns indicadores (como o percentual de escolas com água potável e alimentação) apresentavam valores numéricos "estranhos" (valores absolutos altíssimos) ou zerados. O tratamento foi feito da seguinte forma:

- Fator de Escala (10.000): No código SQL do BigQuery, multipliquei os percentuais por 10.000 (onde 10000 = 100%) para salvá-los como números inteiros, otimizando o

processamento. No Power Query / DAX do Power BI, apliquei a operação de divisão por 10.000 para retornar à escala percentual nativa (0,00 a 1,00).

- Tratamento de Zeros vs. Nulos: Ocorreram registros constando "0". Tive que diferenciar municípios que realmente não tinham estrutura (0% real) dos municípios que simplesmente não enviaram a resposta (Nulo/Branco). No Power BI, utilizei a linguagem DAX com a função IF(ISBLANK([Medida]), BLANK(), [Medida]). Dessa forma, evitei que um município sem dados fosse contado como 0%, o que puxaria a média geral do Estado drasticamente para baixo de forma errônea.

4.2. Anos sem Dados ou com Dados Inconsistentes

Nosso escopo incluiu os anos de 2017 a 2023. Porém, cruzando o Censo com o SISVAN, identificamos uma queda abrupta de avaliações nutricionais nos anos de 2020 e 2021.

Motivo: A pandemia de COVID-19 interrompeu as aulas presenciais e, consequentemente, as avaliações de peso/altura do SISVAN feitas nas escolas.

Tratamento: Decidi não imputar (inventar) médias para esses anos. Os dados ficaram como ausentes (BLANK), e inseri um aviso em formato de "Tooltip" (Dica de Ferramenta) no dashboard do Power BI para alertar o usuário de que os anos de 2020/2021 sofrem de subnotificação severa por conta da pandemia.

5. CONCLUSÃO

A partir do cruzamento, tratamento e visualização dos dados do Censo Escolar e do SISVAN, foi possível validar a hipótese central do projeto: existe uma correlação clara entre a qualidade da infraestrutura escolar, a oferta de alimentação adequada e o desempenho acadêmico dos alunos.

A modelagem evidenciou que municípios e estados com maiores déficits em infraestrutura básica (falta de água potável, coleta de lixo, internet) e maiores índices de vulnerabilidade nutricional tendem a registrar as maiores taxas de abandono e reprovação escolar. Por outro lado, regiões que garantem boa cobertura de infraestrutura e segurança alimentar apresentam consistência em altas taxas de aprovação. O dashboard desenvolvido

cumpre, portanto, o seu papel de ferramenta estratégica, permitindo identificar gargalos geográficos e temporais onde políticas públicas conjuntas de saúde e educação são mais urgentes.

6. REFERÊNCIAS

BASE DOS DADOS. Censo Escolar da Educação Básica - INEP. Base de dados. Disponível em: <https://basedosdados.org/dataset/br-inep-censo-escolar>. Acesso em: 30 set. 2026.

BASE DOS DADOS. Sistema de Vigilância Alimentar e Nutricional (SISVAN) - Ministério da Saúde. Base de dados. Disponível em: <https://basedosdados.org/dataset/br-ms-sisvan>. Acesso em: 30 set. 2026.

BASE DOS DADOS. Diretórios Brasileiros - Municípios. Base de dados. Disponível em: <https://basedosdados.org/dataset/br-bd-diretorios-brasil>. Acesso em: 30 set. 2026.

GOOGLE CLOUD. Documentação Oficial do Google BigQuery. Disponível em: <https://cloud.google.com/bigquery>. Acesso em: 30 set. 2026.